

6+1 麦克风阵列

v1.3.6 架构、v1.4 方向与使用说明

面向首次接触项目的开发与测试人员

发布基线 v1.3.6 | 文档日期 2026-08-27

核心模型：二维远场平面波；只估计相对阵列 x 轴正半轴的方位角，不估计距离和俯仰角。

本文供第一次接触项目的人快速了解系统用途、v1.3.6 处理流程和 Development Test UI 的基本操作。除“版本定位”中的简要说明外，本文参数均指 v1.3.6。

1. 系统要做什么

系统使用半径 4 cm 的 6 个圆周麦克风和 1 个中央麦克风，面向诊室中的多人对话：先判断声音来自哪个方向，再按方向增强和拼接音频，最后判断人声并用声纹归并同一讲话人。

程序采用**二维远场平面波假设**。声源位置只用方位角 `theta` 表示：`theta` 是声源方向与阵列坐标系 x 轴正半轴的夹角，角度范围为 `0~360°`。系统不估计距离和俯仰角，因此讲话人与阵列应尽量位于同一平面。

当前使用场景允许现场共有 3 名讲话人，但假设同一时刻最多 2 人讲话，且两个同时讲话方向的夹角不小于 50°。需要特别区分：L2 最多可以显示 3 条方向轨迹，但 L4 只处理单人或双人音频，不能分离 3 人同时讲话。

2. 版本定位

版本	定位	状态
v1.3.6	完整的 L1 ~ L6 链路，可对双人混合讲话进行方向增强、双人分离、人声检测和匿名声纹归并	已发布
1.4	只保留 IMCRA、DOA 和方向 ID 跟踪预测，目标是轻量、实时、稳定地定位 1 ~ 3 个声源方向	开发中

1.4 正在单独精简，本文不展开其内部实现；旧的完整处理链以不可变标签 v1.3.6 为准。

3. v1.3.6 整体架构



各层的作用如下：

1. **L1**：读取并校准麦克风阵列音频，送往录音服务保存；使用 IMCRA 持续估计环境底噪并输出每 20 ms 的声源概率 **p**。
2. **L2**：Gate 先过滤无明显声源的窗口；随后在 2000 ~ 4000 Hz 运行加权 frequency-normalized MUSIC，输出最多 3 个、两两至少相隔 50°的方向；Circular IMM-JPDA 负责保持方向 ID 并预测短时运动。
3. **L3**：提供 DS、Loaded MVDR 和 optimized 三种模式。DS 最快；Loaded MVDR 稍慢但可实时；optimized 会根据空间可分性选择 LCMV 或 MVDR，双声源路径计算较重。

- 4. **音频拼接**：L3 之后由 TrackAudioStreamHub 按方向 ID 去重、补洞并拼成连续音轨，这不是 L3 波束形成算法本身的职责。
- 5. **L4**：单人轨当前直接旁路；双人轨使用 MossFormer2（或 TIGER）估计两条匿名讲话音轨。输出是算法估计结果，不能理解为无失真的“原始声音”。
- 6. **L5**：使用未经项目微调的 NVIDIA 多语言 MarbleNet 模型判断每个 20 ms 片段是否为人声，不进行语音转写。当前观察中英文人声检测优于中文，中文诊室数据仍需专项验证。
- 7. **L6**：从人声片段提取 CAMPPlus 声纹，结合音频质量分数做跨轨匹配和聚类；结果是匿名的 Speaker A、B 等，不是现实人物身份。

4. v1.3.6 L1 : IMCRA 底噪估计与声源概率

4.1 输入和更新节拍

参数	当前值
参与计算的物理麦克风	7 路：6 个圆周麦 + Center
采样率	48 kHz
每次更新长度	960 sample，即 20 ms
FFT 长度	2048
分析窗	periodic Hann
IMCRA 预热时间	1 秒
保存的 IMCRA 频率范围	0 ~ 10000 Hz

设备原始输入还有一路 **HardwareMix**，但它没有物理坐标，不参与 IMCRA 的 7 麦空间统计、MUSIC 或波束形成。

4.2 IMCRA 输出什么

IMCRA 会对每个麦克风、每个频率点持续维护：

8. 当前信号功率和递归环境噪声功率谱 `noise PSD`;
9. 该频率点存在语音的概率 `SPP ∈ [0,1]`;
10. 供后续算法使用的 7×7 空间噪声协方差。

噪声估计会在可能存在语音时降低更新速度，避免把持续讲话直接学成环境底噪。开始采集后的前 1 秒用于建立初始统计，此时 Gate 保持预热状态。

4.3 每 20 ms 概率 p 如何得到

L1 不是对整个频谱简单求平均，而是先对每个麦克风分别计算三段 SPP 均值，再按固定权重组合：

P Gate 证据频段	权重	作用
250 ~ 700 Hz	15%	保留人声低频基础信息，但降低低频环境噪声影响
700 ~ 1600 Hz	35%	覆盖主要人声能量和部分共振峰
1600 ~ 3400 Hz	50%	强调更容易区分人声活动的中高频信息

```
单麦  $p = 0.15 \times \text{mean}(\text{SPP}_{250-700})$ 
       $+ 0.35 \times \text{mean}(\text{SPP}_{700-1600})$ 
       $+ 0.50 \times \text{mean}(\text{SPP}_{1600-3400})$ 
```

```
阵列  $p = 7$  个物理麦单麦  $p$  的中位数
```

取中位数可以降低某一个麦克风被敲击、近场噪声或异常增益影响整块阵列判断的概率。这里的 p 表示当前 20 ms 内存在符合 IMCRA 语音频谱特征的声源证据，不是响度，也不是最终的“此人正在说话”语义结论。

4.4 P Gate 门限

本文运行口径使用 $p \geq 0.80$ ：

11. $p \geq 0.80$ ：Gate OPEN，允许 L2 继续运行 MUSIC；
12. $p < 0.80$ ：Gate CLOSED，本窗口跳过 MUSIC，减少静音和普通底噪带来的误定位与计算量；
13. Gate 只使用与当前窗口末端严格对齐的最新 20 ms 概率，比较包含等号。

v1.3.6 仓库 `config/config.yaml` 的发布默认值为 `0.60`。按本文流程测试时，应在 Test UI 把 Gate 设为 `0.80` 并点击“应用”；频带和权重仍使用上述 `250 ~ 3400 Hz` 三段配置。

5. v1.3.6 L2 : Norm-MUSIC 定位与方向 ID

5.1 为什么定位使用 2000~4000 Hz

P Gate 和 MUSIC 解决的是两个不同问题：P Gate 判断“现在是否有值得定位的声音”，MUSIC 判断“声音来自哪个方向”。MUSIC 只使用 `2000 ~ 4000 Hz`，因为 4 cm 小孔径阵列在低频上的麦间相位差太小，方向可分性较差；过高频率又更容易受到空间混叠、混响和麦克风误差影响。2 ~ 4 kHz 是在当前阵列尺寸和人声之间采用的折中频段。

5.2 Norm-MUSIC 处理参数

参数	当前值
输入	7 路校准物理麦音频
滚动协方差历史	200 ms
STFT 窗 / 步长	20 ms / 10 ms
FFT 长度	1024
定位频率	2000 ~ 4000 Hz
角度扫描	0 ~ 359°，步长 1°
峰值最低归一化分数	0.35
峰值 prominence	0.05
候选最小圆周间隔	50°
最大公开方向数	3；Test UI 默认 MUSIC 阶数为 2

“frequency-normalized”表示每个频率点先把自己的 360°MUSIC 谱独立归一化，再按阵列几何权重融合。这样可以避免某个能量特别大的频率点单独控制最终方向。

MUSIC 频段	融合权重
2000 ~ 2300 Hz	0.35
2300 ~ 2500 Hz	0.55
2500 ~ 2700 Hz	0.75
2700 ~ 3000 Hz	0.90
3000 ~ 3600 Hz	1.00
3600 ~ 3800 Hz	从 1.00 线性降到 0.75
3800 ~ 4000 Hz	从 0.75 线性降到 0.45

融合后的 360°响应再次归一化，寻找局部峰；低于 0.35 或不够突出的峰被删除，再用 50°圆周 NMS 抑制过近的重叠候选，最终保留不超过当前 MUSIC 阶数且最多 3 个方向。

5.3 ID 跟踪与预测

MUSIC 每个窗口只提供瞬时角度，Circular IMM-JPDA 负责把连续窗口中的同一方向关联为稳定 track_id:

- 14. IMM 在“基本静止”和“缓慢移动”两个运动模型间自动切换，并短时预测下一角度；
- 15. 新方向在 500 ms 内累计至少 10 次匹配观测后转为正式 ID；
- 16. 关联角度硬门限为 50°，最大建模角速度为 60°/s；
- 17. 正式方向短时消失后最多继续预测 2 秒，便于跨越短暂停顿；
- 18. 内部最多维护 4 条轨迹，公共输出最多 3 条。

方向 ID 只代表一条空间轨迹，不代表现实人物身份。人物是否相同要到 L6 通过声纹进行全局判断。

6. 当前状态与限制

19. 根据操作者提供的测试观察，L1 和 L2 已连续运行约 3 小时，方向定位总体实时、稳定且较准确；但该结果仍需保存配置和日志后才能作为正式验收证据。
20. 测试中观察到进程专用内存约每分钟增加 1.7 MB，原因仍待定位。
21. L3 的 DS 和 Loaded MVDR 可以实时运行；optimized 空间可分性路径较慢，可能影响整链输出速度。
22. 4 cm 阵列对低频缺少足够空间差异，约 80 ~ 1500 Hz 的双声源分离效果较差。
23. 近距离声源、明显不共面声源、夹角小于 50°或三人同时讲话，均不属于当前可靠使用范围。

7. v1.3.6 使用方法

在项目根目录启动 Development Test UI：

```
powershell -NoProfile -ExecutionPolicy Bypass -File .\scripts\launch_dev_test_ui.ps1
```

只做方向定位（L1+L2）

24. 连接麦克风阵列并启动 test ui 界面。
25. 点击“启动采集”。真实麦克风模式在正式录音开始前会保持 L3/4/5 关闭，L1 和 L2 正常运行。
26. 将 L2 区域的 Gate 设为 0.80 并点击“应用”，然后观察 Gate、方向角和方向 ID。（默认 0.8）
27. 点击“停止采集”结束。该流程可以重复运行。

运行完整 L1~L6

28. 点击“启动采集”，等待 L1 和 L2 完成预热；将 Gate 设为 0.80 并点击“应用”。
29. 点击“正式录音开始”。程序会重置本轮方向轨迹、自动开启 L3/4/5，并开始保存正式音频。
30. 采集中可查看 DOA、方向 ID、L3 音轨以及渐进的 L4 ~ L6 预览。
31. 结束时先点击“正式录音暂停”，再点击“停止采集”。

32. 等待界面完成队列排空、音轨封存及 L4 ~ L6 最终处理后再关闭程序。

界面上方的“录制 / 暂停 / 结束”是独立的 scratch 临时录音，不会启动完整 L1 ~ L6 流程；完整流程必须使用“正式录音开始”。L6 没有独立开关，会跟随完整处理链自动运行。

v1.3.6 的完整可执行状态以不可变 Git 标签 `v1.3.6` 为准；v1.4 的实际默认参数以 [`../config/config.yaml`](#) (`../config/config.yaml`) 为准。